

VILNIAUS UNIVERSITETAS MATEMATIKOS IR INFORMATIKOS
FAKULTETAS

KURSINIS DARBAS

VEIKSNIŲ KURIE PASKATINA DARBUOTOJUS PALIKTI SAVO DARBO
VIETĄ STATISTINĖ ANALIZĖ

JURGIS SAMAITIS

2017

1 TURINYS

2	Įvadas.....	3
3	Literatūros Apžvalga	3
4	Aprašomoji Statistika	4
4.1	Duomenys.....	4
4.2	Pradinė duomenų analizė	5
4.3	Analizė pagal grupę.....	6
5	Ekonometrinė duomenų analizė.	10
5.1	Logistinė Regresija.....	10
5.2	Naivusis Bayes Metodas	12
5.3	Ekonometrinės duomenų analizės išvados	14
6	Prognozavimo Modelių Kūrimas.....	14
6.1	Naudojami modeliai ir argumentacija	14
6.2	Atraminių Vektorių Klasifikavimo Algoritmas	14
6.3	Atsitiktinio Miško Metodas.....	15
6.4	Prognozavimo modelių rezultatų palyginimas	15
7	Išvados	16
8	Literatūra	16

2 ĮVADAS

Prarasti darbuotoją, kompanijai gali kainuoti nuo dešimčių tūkstančių iki 1.5-2 kartų to darbuotojo metinio atlyginimo [1]. Kadangi kompanijos siekia sumažinti savo kaštus, kiekvienas darbuotojas, kol jis teikia bent kažkiek naudos, yra finansinė vertybė. Nustatyti, kodėl darbuotojai palieka kompaniją ne visada yra paprasta ir darbuotojo noras palikti darbovietę kartais atrodo neracionaliai iš pirmo žvilgsnio. Šiame darbe ištyrėme kaip galime tokį „neracionalų“ darbuotojo pasirinkimą palikti savo darbo vietą paaiškinti ir kokie veiksniai lemia šį sprendimą.

Taip pat, sukūrėme prognozavimo modelį, kuris kompanijoms turėtų padėti kuo tiksliau nustatyti ar darbuotojas ketina išeiti iš kompanijos. Tikėtina kad tokio modelio naudojimas sutaupytų didžiąją dalį susidariusių kaštų dėl darbuotojo išėjimo, nesukurdamas sąlyginai didelių išlaidų kurios atsirastų vertinant šią problemą. Taip pat, veiksnių analizė ir prognozavimo modelio naudojimas galėtų padėti kompanijoms spręsti darbuotojų noro palikti kompaniją problemą tikslingai, o ne naudoti įprastus, nusistovėjusius ir dažnai neefektyvius metodus.

3 LITERATŪROS APŽVALGA

2015 metais, JAV atlikta apklausa parodė kad esminiai dalykai kurie daro esminę įtaką darbuotojų sprendimui palikti savo darbovietę yra pagarba/nepagarba iš viršininkų ar kolegų, darbovietės kultūros lygis bei komandos formavimo renginiai (angl. “Team-building events”), atostogų kiekis ir kokybė bei aiškių galimybių augti darbovietėje buvimas [2]. 2014 metais Pakistane atlikti tyrimai parodė kad taip pat yra svarbūs šie veiksniai: įsitraukimas į kompanijos veiklą bei kompanijos ateities vizijos matymas, streso kiekis ir pasitenkinimo darbovieta lygis [3].

Pasitenkinimo lygis kaip esminis kintamasis kuris veikia darbuotojo norą išeiti iš darbo vietos pasirodo ne viename tyrime [3], [4], [5], todėl tikėtina kad kiti kintamieji yra “pagalbiniai” kintamieji, kurie stipriai koreliuoja su pasitenkinimo lygiu ir leidžia geriau paaiškinti darbuotojo sprendimą palikti savo darbo vietą. Mūsų duomenys yra platesnio spektro negu radome literatūroje aptartus kintamuosius, todėl galėsime geriau ir plačiau paaiškinti darbuotojo sprendimą palikti savo darbo vietą.

Taip pat, minėti tyrimai buvo atlikti apklausos ir statistiniu tyrimų metodika, tačiau statistinių modelių neradome. Kategorinių duomenų analizėje statistiniai modeliai dažnai yra *juodosios dėžės* (angl. „Black Box”), t.y. neparodo konkrečių rezultatų, nepaisant šių modelių labai tikslaus prognozavimo. Būtent dėl šios priežasties šiame darbe analizuosime pasitelkę 2

pagrindinius modelius: Logistinę Regresiją bei Naivųjį Bayes Metodą [6], [7], kurių rezultatus galima lengvai interpretuoti norint paaiškinti kintamųjų įtaką darbuotojo norui palikti kompaniją.

Dėl didelio kintamųjų kiekio, darbdaviams kyla problema nuspėti darbuotojo norą palikti savo darbo vietą, tol kol darbuotojas pats neišeina. Kadangi 78% darbdavių JAV yra suinteresuoti neprarasti gerų darbuotojų [2], gebėjimas iš anksto nustatyti darbuotojo norą palikti darbo vietą gerokai sumažintų išlaidas šioje srityje. Šiam tikslui pasitelksime anksčiau minėtus Logistinę Regresiją ir Naivųjį Bayes Metodą, bei vadinamuosius *juodosios dėžės* modelius - Atraminių Vektorių Klasifikavimo Algoritimą ir Atsitiktinio Miško Metodą dėl šių modelių galimybės labai tiksliai klasifikuoti tokio tipo duomenis [8], [9].

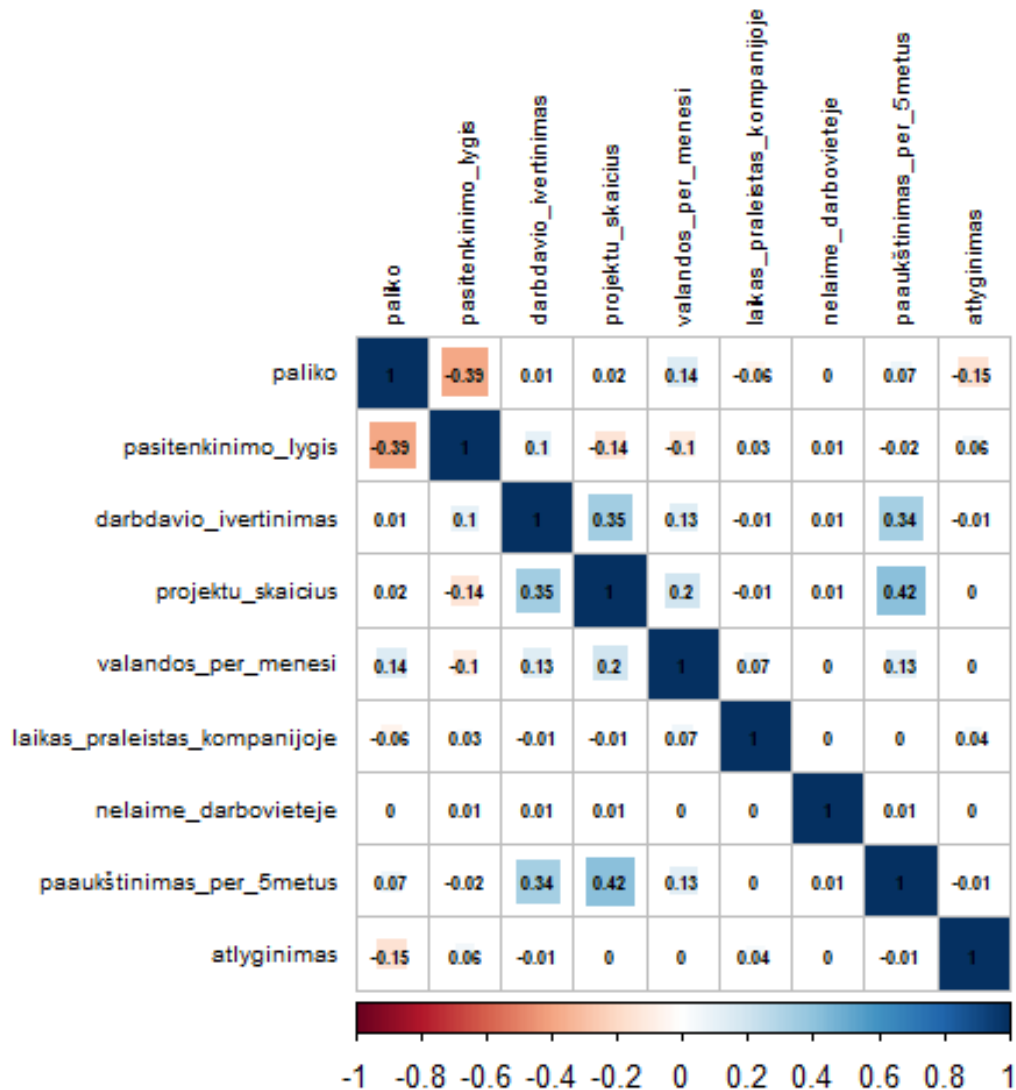
4 APRAŠOMOJI STATISTIKA

4.1 DUOMENYS

paliko	Tiriamasis kintamasis. Apibūdina ar darbuotojas paliko savo darbovietę. Kategorinis kintamasis.
pasitenkinimo_lygis	Apibūdina darbuotojo pasitenkinimo lygį savo darbovietėje procentais.
darbdavio_įvertinimas	Apibūdina darbdavio pasitenkinimo lygį darbuotoju procentais.
projektų_skaičius	Apibūdina darbuotojui paskirtų projektų skaičių vienetais.
valandos_per_mėnesį	Apibūdina vidutinį darbuotojo darbo laiką per mėnesį valandomis.
laikas_praleistas_kompanijoje	Apibūdina kiek laiko darbuotojas dirba dabartinėje kompanijoje metais.
nelaimė_darbovietėje	Apibūdina ar darbuotojas patyrė traumą darbo metu, dabartinėje darbovietėje. Kategorinis kintamasis.
paaukštinimas_per_5metus	Apibūdina ar darbuotoją paaukštino pareigybėse per paskutinius penkis metus. Kategorinis kintamasis.
sritis	Apibūdina darbuotojo darbo sritį (IT, projektų vadovas, pardavimų skyrius ir t.t.). Kategorinis kintamasis.
atlyginimas	Apibūdina darbuotojo atlyginimą (mažas, vidutinis, didelis). Kategorinis kintamasis.

4.2 PRADINĖ DUOMENŲ ANALIZĖ

Tirsime koreliaciją tarp duomenų, tačiau ne visų – kadangi kintamasis *sales* yra nominalus, jo į koreliacijos tarp kintamųjų skaičiavimą neįtrauksime.

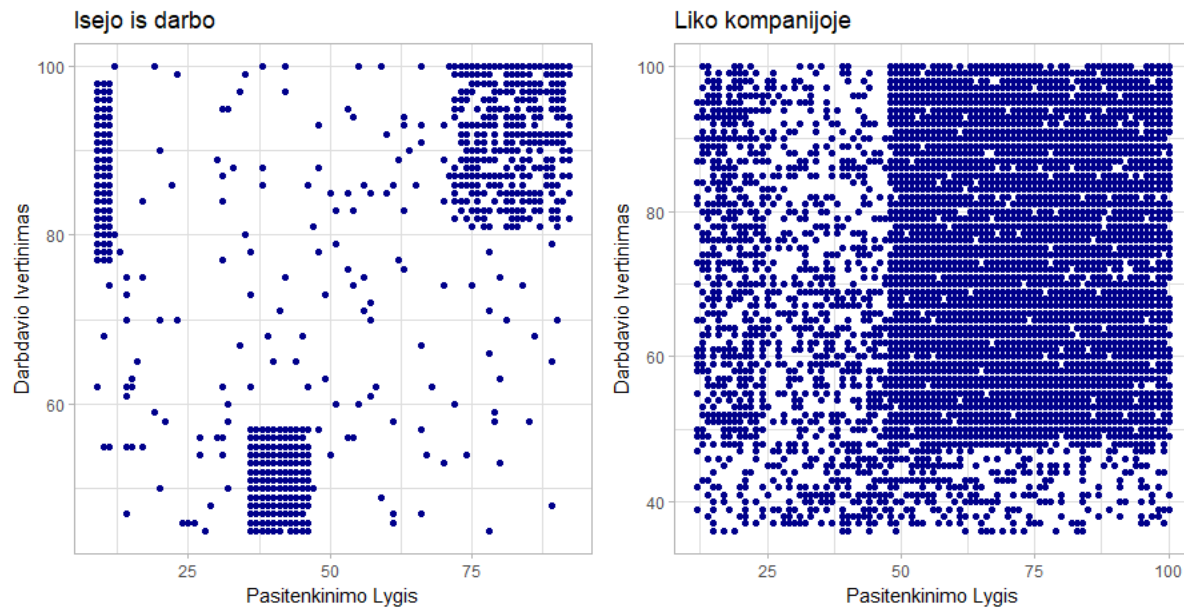


Matome, kad pasitenkinimo lygis ir atlyginimas, tikėtinai padidina norą palikti kompaniją, tačiau didelis investuotas laikas į šią kompaniją darbuotojus „pririša“ prie darbovietės ir mažina norą palikti.

4.3 ANALIZĖ PAGAL GRUPĘ

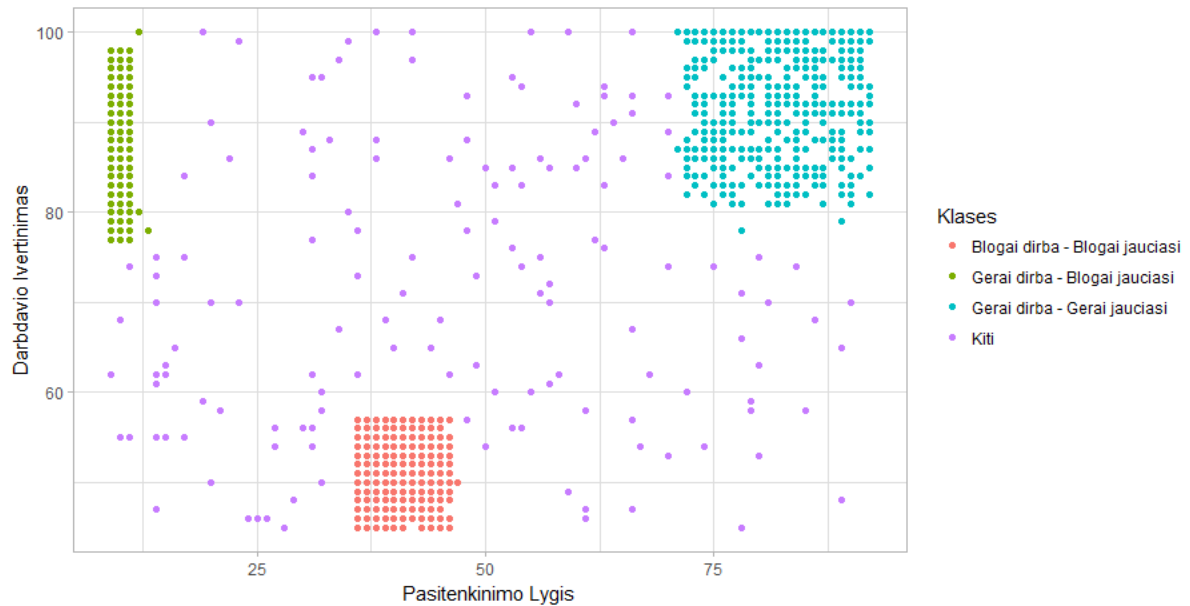
Tikėtina, kad žmonės kurie išėjo iš darbovietės ir tie kurie pasiliko joje, turi visiškai skirtingus kompanijos įvaizdžius, todėl jas tiriant kartu nematysime jokių rezultatų.

Pažvelgę į ryšį tarp darbdavio darbuotojo įvertinimo ir pačio darbuotojo pasitenkinimo lygio matome, kad egzistuoja ryškus pasiskirstymas:




Tuos kurie paliko kompaniją galime išskirti į tris grupes:

- 1) Nepatenkinti savo darbu, tačiau geri darbuotojai. Ši grupė, nepaisant nepasitenkinimo savo darbu, vis tiek puikiai atlieka savo pareigas. Juos vadinsime *Gerai dirba – Blogai jaučiasi*.
- 2) Nepatenkinti savo darbu ir tuo pačiu prasti darbuotojai. Ši grupė tikriausiai paprasčiausiai dirba ne toje vietoje kur turėtų ir dėl to jaučiasi prastai, taipogi ir dirba prastai. Juos vadinsime *Blogai dirba - Blogai jaučiasi*.
- 3) Patenkinti savo darbu ir tuo pačiu geri darbuotojai. Ši grupė žmonių neturi racionalios priežasties palikti savo darbo vietą, todėl tikėtina kad gavo geresnį pasiūlymą iš kitos darbovietės. Juos vadinsime *Gerai dirba – Gerai jaučiasi*.

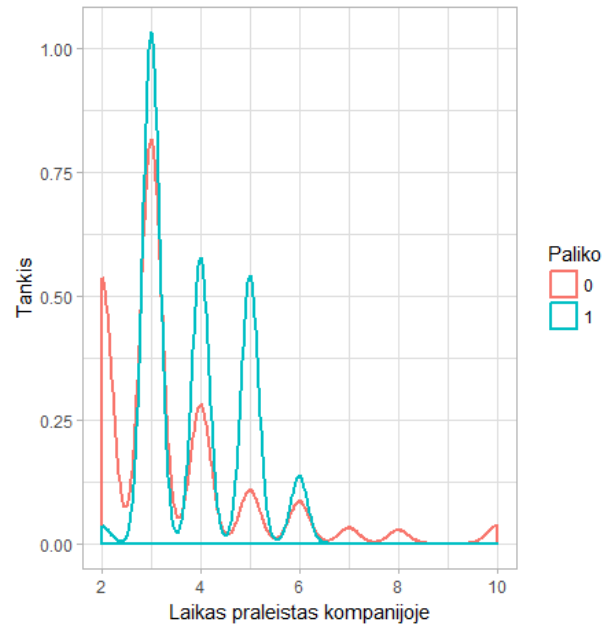



Matome, kad tiriamųjų pasiskirstymas labai skiriasi nuo to ar jie paliko kompaniją ar ne, todėl tirsime kintamųjų pasiskirstymo tankio grafikus išskyrę pagal tai ar jie paliko kompaniją ar liko dirbti.



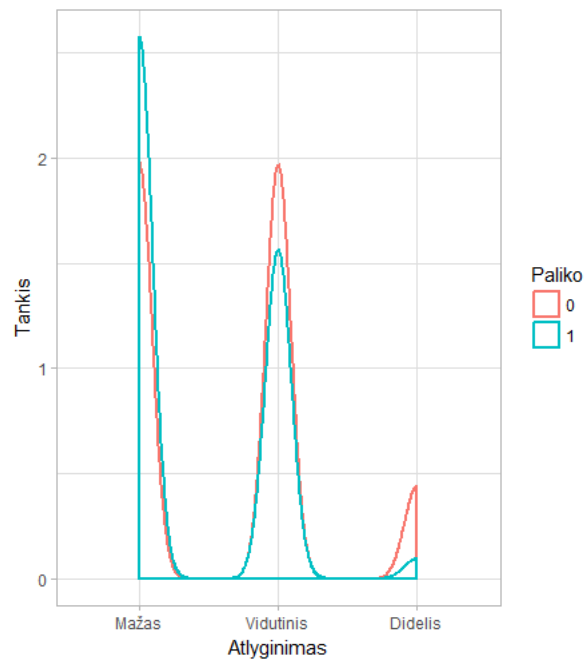
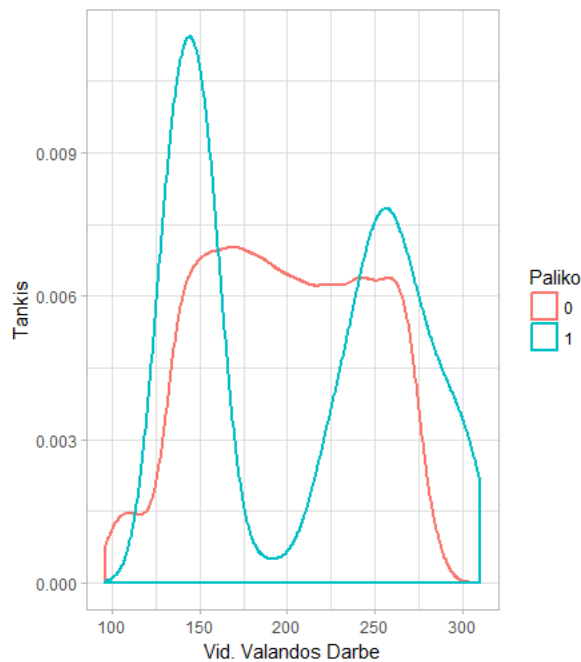
Matome, kad pasitenkinimo lygiui esant žemiau 50, galime užtikrintai teigti, kad darbuotojas paliks kompaniją, tačiau šis skirtumas tampa ne toks ryškus pasitenkinimo lygiui esant didesniau nei 50.

Taip pat, žmonės kurie paliko kompaniją buvo darbdavio įvertinti arba prastai arba labai gerai, todėl „vidutiniškai“ (60 - 80 lygyje) tikėtina kad pasiliks dirbti kompanijoje.




Matome kad darbuotojai kurių galimybės yra neišnaudojamos, t.y. dirba su mažai projektų labiau nori palikti kompaniją. Noras išeiti taip pat didėja projektų skaičiui esant daugiau nei 5, tikėtina dėl minėto persidirbimo [2].

Kuo daugiau praleidžiama laiko kompanijoje – tuo mažiau darbuotoju palieka kompaniją.




Matome kad tie, kurie išeina iš darbo dirba arba labai daug, arba labai mažai – šis kintamasis taip pat koreliuoja su projektų skaičiumi ir pagrindžia teiginį kad kai kurie

darbuotojai jaučiasi kad jų potencialas yra neišnaudojamas, todėl nusprendžia palikti darbo vietą. Aukštesnis atlyginimas, kaip ir tikėjomės, sumažina darbuotojo norą palikti kompaniją.



Vadybos srityje ir Mokslinių Tyrimų bei Plėtos srityse esantys žmonės akivaizdžiai mažiau palieka savo darbo vietą, o Apskaitos ir Žmogiškųjų išteklių, skyriuose dirbantys žmonės yra linkę palikti darbovietę.



Keista kad tie kurie patiria nelaime darbovietėje yra linkę likti kompanijoje. Akivaizdaus logiško paaiškinimo tam nėra. Darbuotojai neseniai paaugstininti pareigose labiau linkę likti kompanijoje.

5 EKONOMETRINĖ DUOMENŲ ANALIZĖ.

Norėdami išsiaiškinti kaip ir kokie kintamieji daro įtaką mūsų aiškinamajam kintamajam Paliko, kuris apibūdina ar darbuotojas išėjo iš darbo (paliko kompaniją), naudosime 2 metodus – Logistinę Regresiją ir Naivųjį Bayes Metodą. Šių modelių rezultatus lyginsime tarpusavyje stengdamiesi kuo tiksliau paaiškinti kintamųjų įtaką.

5.1 LOGISTINĖ REGRESIJA

Pritaikę mūsų modelį duomenims gavome kad visi kintamieji yra reikšmingi. Gautus modelio koeficientus pavertėme šansų santykiais (angl. „Odds ratio“), dėl jų paprastesnio interpretavimo:

Tolygieji kintamieji:



Pasitenkinimo Lygis	0.959617
Darbdavio Įvertinimas	1.008096
Projektų Skaičius	0.732899
Laikas Praleistas Kompanijoje	1.307761
Vidutinės Darbo Valandos	1.00441

Matome, kad kiekvienai metų praleisti dirbant kompanijoje, labiausiai daro įtaką darbuotojo norui palikti savo darbo vietą.

Šis rezultatas nėra intuityvus, tačiau pasiskirstymo grafike matome, kad kiekis žmonių kurie paliko darbo vietą, staigiai didėja kai *Laikas praleistas kompanijoje* didėja ir ryškiai atsiskiria nuo tų kurie pasiliko darbovietėje. Būtent todėl, Logistinės Regresijos modelis šiam kintamajam priskiria tokią didelę reikšmę.

Priešingu atveju, kiekvienas papildomas projektas sumažina šį šansą 0.7 karto. Tai irgi matosi iš pasiskirstymo grafiko – žmonių kurie linkę turėti nuo 3 iki 5 projektų yra daugiau pasilikusių dirbti negu išėjusių iš darbo.

Pasitenkinimo lygis taip pat mažina šansą palikti darbovietę, tačiau neturi tokio staigaus efekto kaip *Projektų Skaičius* kintamasis.



Paaukštinimas Pareigose	
Ne	1
Taip	0.28121

Paaukštinimas pareigose labai sumažina šansą kad darbuotojas paliks savo darbo vietą.

Atlyginimas	
Aukštas	1
Vidutinis	4.034071
Mažas	7.242949

Kuo mažesnis atlyginimas, tuo didesnis šansas kad darbuotojas paliks darbo vietą. Šansas kad darbuotojas gaunantis *mažą* atlyginimą paliks savo darbo vietą yra net 7 kartus didesnis negu darbuotojo kuris gauna *aukštą* atlyginimą.

Nelaimė Darbovietėje	
Ne	1
Taip	0.187749

Nelaimė darbovietėje taip pat stipriai sumažina tikimybę kad darbuotojas liks dirbti.

Skyrius	
Apskaita	1
Žmogiškieji Ištekliai	1.390506
IT	0.881797
Vadyba	0.659046
Marketingas	0.994892
Produktų Vadybininkai	0.908011
Moksliniai Tyrimai ir Plėtra	0.567678
Pardavimai	1.045373
Pagalbos Skyrius	1.122419
Technika	1.097521

Darbuotojai dirbantys *Žmogiškųjų Išteklų* skyriuje, labiausiai skiriasi nuo mūsų „standartinės“ *Apskaitos* pozicijos – jų šansas palikti firmą padidėja 1.39 karto. Priešingu atveju, žmonės dirbantys *Vadybos* ir *Mokslinių Tyrimų ir Plėtros* skyriuose, yra labiausiai lojalūs.

5.2 NAIVUSIS BAYES METODAS

Šis algoritmas neteikia jokių naudingų įžvalgų apie tolygiuosius kintamuosius, todėl pateiksime tik kategorinių kintamųjų rezultatus.

Algoritmas apskaičiavo sąlygines tikimybes kiekvienam kintamajam. Šios lentelės interpretuojamos taip – jeigu įvyko kintamojo X įvykis A (*Paaukštino pareigose*, *Nepaaukštino pareigose*), tai tikimybė, *ceteris paribus*, kad darbuotojas paliks firmą padidėja/sumažėja tuo, kas yra pateikta lentelėje.

Tikimybės Skirtumas	Paaukštinimas Pareigose	
	Ne	Taip
	0.02	-0.02

Tikimybės Skirtumas	Nelaimė Darbovietėje	
	Ne	Taip
	0.126	-0.126

Tikimybės Skirtumas	Atlyginimas		
	Žemas	Vidutinis	Aukštas
	0.157	-0.08	-0.078

Matome kad rezultatai labai panašūs į Logistinės Regresijos – *Nelaimė darbovietėje* bei *Atlyginimo dydis* daro didelę įtaką darbuotojo norui palikti kompaniją.

Tikimybės Skirtumas	Skyrius				
	Apskaita	Žmogiškieji Ištekliai	IT	Vadyba	Marketingas
	0.006	0.012	0	-0.018	0.002

Tikimybės Skirtumas	Skyrius				
	Produktų Vadyb.	Moksliniai Tyrimai ir Plėtra	Pardavimai	Pagalbos Skyrius	Technika
	-0.011	-0.02	0.007	0.007	0.017

Taip pat matome kad *Žmogiškųjų išteklių* srityje dirbantys darbuotojai yra linkę palikti savo darbo vietą, o *Vadybininkais*, *Produktų vadybininkais* ir *Mokslinių tyrimų bei plėtros* srityse dirbantys darbuotojai labiau linkę pasilikti dirbti. *IT* skyriuje esantiems darbuotojams pagal šio modelio rezultatus norui palikti savo darbo vietą nedaro įtakos tai kad jie dirba IT skyriuje.

Tikėtina kad darbuotojo *Skyrius* turėtų daryti įtaką jo *Pasitenkinimo Lygiui*.

Skyrius	Vidutinis Pasitenkinimo Lygis
Vadyba	62.1
Moksliniai Tyrimai ir Plėtra	62.0
Produktų Vadybininkai	62.0
Marketingas	61.9
Pagalbos Skyrius	61.8
IT	61.8
Pardavimai	61.4
Technika	60.8
Žmogiškieji Ištekliai	59.9
Apskaita	58.2

Matome, kad vidutinis pasitenkinimo lygis aiškiai yra didesnis minėtose srityse, o *Žmogiškųjų Išteklų* srityje dirbantys žmonių pasitenkinimo lygis yra beveik mažiausias. Apskaita buvo mūsų „standartinė“ pozicija, tuo pačiu ir mažiausiai patenkintų darbuotojų sritis.

5.3 EKONOMETRINĖS DUOMENŲ ANALIZĖS IŠVADOS

Iš rezultatų matome, kad dauguma kintamųjų atitinka pradines prognozes – žemas atlyginimas, patirta trauma darbe, vidutinės darbo valandos bei trumpas laikas praleistas šioje darbovietėje daro neigiamą įtaką darbuotojo sprendimui palikti kompaniją, tačiau aukštas pasitenkinimo lygis, bei darbuotojo užimtumas projektais (iki tam tikros ribos) skatina darbuotoją pasilikti kompanijoje.

Taip pat matėme, kad sritis, kurioje darbuotojas dirba motyvuoja arba demotyvuoja darbuotoją pasilikti dirbti, priklausomai nuo šios srities.

6 Prognozavimo Modelių Kūrimas

6.1 NAUDOJAMI MODELIAI IR ARGUMENTACIJA

Prognozavimo modelio kūrimui naudosime šiuo metu populiariausius klasifikavimo modelius: Atraminių Vektorių Klasifikavimo Algoritmą (angl. „Support Vector Machines“), Naivusis Bayes Metodas (angl. „Naive Bayes“), Atsitiktinio Miško Metodą (angl. „Random Forest“) ir Logistinę Regresiją. Šiuos modelius pasirinkome dėl jų paprasto, tačiau tikslaus klasifikavimo problemos sprendimo.

Norėdami patikrinti mūsų klasifikavimo algoritmų tikslumą, turimus duomenis atsitiktine tvarka suskirstėme į 2 dalis – 70% (10499 eilutės) duomenų bus naudojama modelio paruošimui, o likę 30% (3252 eilutės) bus taikomi modelio tikslumo tikrinimui. Šiuos duomenis atitinkamai vadinsime *mokymo duomenimis* ir *tikrinimo duomenimis* [6].

6.2 ATRAMINIŲ VEKTORIŲ KLASIFIKAVIMO ALGORITMAS

Pritaikę šį algoritmą su įvairiais parametrais, tiksliausio modelio rezultatus gavome tokius:

Modelio Spėjimai:	Realios reikšmės	
	Liks Darbe	Išeis
Liks Darbe	2773	39
Išeis	45	382

Tikslumas:	97.4%
95% Pasiklioavimo intervalas:	(96.80%, 97.93%)

6.3 ATSITIKTINIO MIŠKO METODAS

Pritaikę šį algoritmą su įvairiais parametrais gautus rezultatus pateikiame lentelėse:

Modelio Spėjimai:	Realios reikšmės	
	Liks Darbe	Išeis
Liks Darbe	2827	33
Išeis	4	387

Tikslumas:	98.9%
95% Pasiklivimo intervalas:	(98.43%, 99.20%)

6.4 PROGNOZAVIMO MODELIŲ REZULTATŲ PALYGINIMAS

Kaip ir buvo minėta pradžioje, į šiuos rezultatus įterpsime ir Logistinės Regresijos bei Naiviojo Bayes metodo rezultatus. Rezultatus pateikiame lentelėje:

	Modelio Tikslumas	95% Pasiklivimo Intervalas	
Atsitiktinio Miško Metodas	98.90% (3216 / 3252)	98.43%	99.20%
Atraminių Vektorių Klasifikavimo Algoritmas	97.40% (3168 / 3252)	96.80%	97.93%
Naivusis Bayes Metodas	87.10% (2833 / 3252)	85.90%	88.24%
Logistinė Regresija	84.73% (2755 / 3252)	83.44%	85.95%

Iš rezultatų matome, kad yra aiški tendencija – kuo modelis daugiau gali mums pasakyti apie pačius kintamuosius, tuo jo tikslumas mažėja. Tiksliausias Atsitiktinio Miško Metodas neteikia jokios informacijos apie tai kaip ir kodėl jis priskiria tam tikras taisykles kiekvienam kintamajam, tačiau nepaisant to, firmoms kurios siekia išsiaiškinti kuris jų darbuotojas sekantis paliks savo darbo vietą, šis modelis yra geriausias įrankis iš mūsų tirtųjų.

7 IŠVADOS

Ištyrę veiksnius, radome, kad esminiai dalykai kurie paskatina darbuotoją toliau pasilikti dirbti yra: aukštas pasitenkinimo lygis, paaukštinimas pareigose, didelis atlyginimas ir ilgas laikas praleistas dabartinėje darbovietėje. Priešingu atveju, žemas pasitenkinimo lygis, darbuotojo netiesioginis “persidirbimas”, kurį atspindi didelis projektų skaičius bei nelaimė darbovietėje.

Nustatėme kad darbuotojų noras palikti kompaniją labai priklauso nuo skyriaus kuriame dirbama – apskaitoje ir žmogiškuosiuose ištekliuose dirbantys darbuotojai yra linkę labiau palikti darbovietę. Priešingai – Vadybininkai (Vadyba ir Produktų Vadybininkai) ir Moksliniuose Tyrimuose bei Plėtroje dirbantys darbuotojai yra labiausiai „lojalūs” skyriai iš visų.

Taigi norint nustatyti darbuotojų priežastis dėl paliktos darbovietės, visų pirmą reikėtų atsižvelgti į skyrių kuriame jis dirba, svarbius, tačiau retus veiksnius, tokius kaip paaukštinimas pareigose ar nelaimingas atsitikimas, ir tik galų gale lyginti darbuotojo realius darbo rezultatus – projektų skaičių, pasitenkinimo lygį ir pačio darbdavio įvertinimą.

Taip pat sukūrėme Atsitiktinio Miško Metodo modelį, kurio pagalba galima lengvai įvertinti visus šiuos veiksnius ir nustatyti ar darbuotojas paliks savo darbo vietą vidutiniškai 98.9% tikslumu. Kompanijos galėtų pasitelkti šį modelį norėdamos greitai ir efektyviai gauti rezultatus – tokiu būdu sutaupytų reikšmingą kiekį kaštų, kuriuos priešingu atveju išleistų naujų darbuotojų apmokymui ar nekryptingų, firmos mastu, kursų, nežinant realių darbuotojų apyvartos (angl. „Employee Turnover”) priežasčių.

8 LITERATŪRA

- [1] [Employee Retention Now a Big Issue: Why the Tide has Turned \(2013\), John Bersin](#)
- [2] [TinyPulse Employee Retention Report \(2015\)](#)
- [3] [Determinants of Employees intention to leave: A Study from Pakistan \(2014\), Muhammad Rizwan Lect., Department of Management Sciences The Islamia University of Bahawalpur, Pakistan](#)
- [4] [Analysis of Factors That Affect the Intention to Leave of White-collar Employees in Turkey Using Structural Equation Modelling \(2013\), Ecem Basak, Esin Ekmekci, Yagmur Bayram, and Yasemin Bas](#)

- [5] [Turnover Intention, Organizational Commitment, and Specific Job Satisfaction among Production Employees in Thailand \(2015\), Yoshitaka Yamazakia, Sorasit Petchdee](#)
- [6] [An Introduction to Categorical Data Analysis \(2007\), Alan Agresti, Department of Statistics University of Florida Gainesville, Florida](#)
- [7] [Artificial Intelligence A Modern Approach \(2003\), Stuart Russell and Peter Norvig](#)
- [8] [Support-Vector Networks \(1995\), Corinna Cortes Vladimir Vapnik](#)
- [9] [Random Decision Forests \(1995\), Tin Kam Ho](#)